

Sistemas Nebulosos

Relações Nebulosas

Cristiano Leite de Castro

Adaptação de material didático do Prof. André Paim Lemos (DELT)

Relação Binária

- Produto Cartesiano

$$U \times V = \{(x, y) | x \in U \text{ e } y \in V\}$$

- Relação binária $R(U, V)$

$$\mu_R(x, y) = \begin{cases} 1 & \iff (x, y) \in R \\ 0 & \text{caso contrario} \end{cases}$$

$$R \subseteq U \times V$$

Relação Binária

- Exemplo:

- $R(U,V) : x \text{ é divisível por } y$

- $U = \{10, 15, 20\}$

- $V = \{2, 3, 5\}$

$R(U,V) = \{(10,2), (10,5), (15,3), (15,5), (20,2), (20,5)\}$

Relação Binária

- Conjuntos ordinários
 - Tupla (elemento) pertence ou não a relação
 - $R(U,V)$: x é divisível por y
 - $U = \{10, 15, 20\}$
 - $V = \{2, 3, 5\}$

$$(10, 2) \in R$$


$$(10, 3) \notin R$$

Relação Binária

$$R : (x - 1)^2 + (y - 1)^2 \leq r^2$$

Centro = (1,1)

Raio = r



Relação Nebulosa

- Representa o *grau* de presença ou ausência de **associação (interação)** entre os elementos de dois ou mais conjuntos nebulosos.
- Exemplos:
 - x é bem maior que y
 - y é muito próximo de x
 - **SE** x é alto **ENTÃO** y é baixo

Relação Nebulosa

- Relação binária nebulosa é um **conjunto nebuloso** definido no **espaço cartesiano $U \times V$**

$$R(U, V) = \{(x, y), \mu_R(x, y) | (x, y) \in U \times V\}$$

- Conjuntos ordinários : $\mu_R(x, y) \in \{0, 1\}$
- Conjuntos nebulosos : $\mu_R(x, y) \in [0, 1]$


Se a relação é definida no espaço $U \times V$ então $\mu_R(.)$ é uma Função de Pertinência Bi-dimensional

Relação Nebulosa

- Exemplo
 - Sejam U e V números reais
 - $R(x,y)$: “ x é próximo de y ”

$$\mu_R(x, y) = \max\{(5 - |x - y|)/5, 0\}$$

Relação Nebulosa



Relação Nebulosa

- $U = V = \{10, 40, 80, 100, 300\}$
- $R(x, y)$: “x é muito maior que y”

$$\mu_R(x, y) =$$

X/Y	10	40	80	100	300
10	0	0	0	0	0
40	0,4	0	0	0	0
80	0,8	0,2	0	0	0
100	1,0	0,6	0,2	0	0
300	1,0	0,8	0,4	0,2	0

Relação Nebulosa

- operações, união, intercessão, complemento também podem ser utilizadas em relações nebulosas

$$\mu_{R \cap S}(x, y) = \mu_R(x, y) \wedge \mu_S(x, y)$$

$$\mu_{R \cup S}(x, y) = \mu_R(x, y) \vee \mu_S(x, y)$$

- o operador é aplicado elemento a elemento.

\wedge = t-norma

\vee = s-norma

Relação Nebulosa

- Exemplo:
 - $U = \{2,12\}$ e $V=\{1,7,13\}$
 - Relações:
 - “u é próximo de v”
 - “u é muito menor que v”

$$\mu_p(u, v) = \begin{pmatrix} 0.9 & 0.4 & 0.1 \\ 0.1 & 0.4 & 0.9 \end{pmatrix}$$

$$\mu_m(u, v) = \begin{pmatrix} 0 & 0.6 & 1 \\ 0 & 0 & 0.3 \end{pmatrix}$$

Relação Nebulosa

- “u é próximo de v” e “u é muito menor que v”

$$\mu_{p \cap m}(u, v) = \mu_p(u, v) \wedge \mu_m(u, v)$$

$$\mu_p(u, v) = \begin{pmatrix} 0.9 & 0.4 & 0.1 \\ 0.1 & 0.4 & 0.9 \end{pmatrix}$$

$$\mu_m(u, v) = \begin{pmatrix} 0 & 0.6 & 1 \\ 0 & 0 & 0.3 \end{pmatrix}$$

$$\mu_{p \cap m}(u, v) = \begin{pmatrix} 0 & 0.4 & 0.1 \\ 0 & 0 & 0.3 \end{pmatrix}$$

Relação Nebulosa

- “u é próximo de v” **ou** “u é muito menor de v”

$$\mu_{p \cup m}(u, v) = \mu_p(u, v) \vee \mu_m(u, v)$$

$$\mu_p(u, v) = \begin{pmatrix} 0.9 & 0.4 & 0.1 \\ 0.1 & 0.4 & 0.9 \end{pmatrix}$$

$$\mu_m(u, v) = \begin{pmatrix} 0 & 0.6 & 1 \\ 0 & 0 & 0.3 \end{pmatrix}$$

$$\mu_{p \cup m}(u, v) = \begin{pmatrix} 0.9 & 0.6 & 1 \\ 0.1 & 0.4 & 0.9 \end{pmatrix}$$

Relação Nebulosa

Example 5.2

Let R be a fuzzy relation between the two sets $X = \{\text{New York City, Paris}\}$ and $Y = \{\text{Beijing, New York City, London}\}$, which represents the relational concept “very far.” This relation can be written in list notation as

$$R(X, Y) = 1/\text{NYC, Beijing} + 0/\text{NYC, NYC} + .6/\text{NYC, London} + .9/\text{Paris, Beijing} + .7/\text{Paris, NYC} + .3/\text{Paris, London}.$$

This relation can also be represented by the following two-dimensional membership array (matrix):

	<i>NYC</i>	<i>Paris</i>
<i>Beijing</i>	1	.9
<i>NYC</i>	0	.7
<i>London</i>	.6	.3

Composição de Relações Nebulosas

- “u é próximo de v” definida em $U \times V$ ($U = \{2, 12\}$ e $V = \{1, 7, 13\}$)

$$\mu_p(u, v) = \begin{pmatrix} 0.9 & 0.4 & 0.1 \\ 0.1 & 0.4 & 0.9 \end{pmatrix}$$

- “v é muito maior que w” definida em $V \times W$ ($W = \{4, 8\}$)

$$\mu_{mm}(v, w) = \begin{pmatrix} 0 & 0 \\ 0.6 & 0 \\ 1 & 0.7 \end{pmatrix}$$


Composição de Relações Nebulosas

- A proposição
 - “u é próximo de v e v é muito maior que w”
- **Composição** de duas relações nebulosas

$$R(U, W) = P(U, V) \circ M(V, W)$$

- $R(U, W)$ é definida em $U \times W$

Composição de Relações Nebulosas



Composição de Relações Nebulosas

- Composição Max-Min:

$$\mu_{P \circ M}(u, w) = \{ (u, w), \max_v [\min(\mu_p(u, v), \mu_M(v, w))] \}$$

$\wedge = \min$

$\vee = \max$

Composição de Relações Nebulosas

- “u é próximo de v e v é muito maior que w”

$$\mu_p(u, v) = \begin{matrix} & \begin{matrix} 1 & 7 & 13 \end{matrix} \\ \begin{pmatrix} 0.9 & 0.4 & 0.1 \\ 0.1 & 0.4 & 0.9 \end{pmatrix} & \begin{matrix} 2 \\ 12 \end{matrix} \end{matrix}$$

$$\begin{matrix} & \begin{matrix} 4 & 8 \end{matrix} \\ \begin{pmatrix} 0 & 0 \\ 0.6 & 0 \\ 1 & 0.7 \end{pmatrix} & \begin{matrix} 1 \\ 7 \\ 13 \end{matrix} \end{matrix} \quad \Rightarrow \quad \mu_{p \circ mm} = \begin{matrix} & \begin{matrix} 4 & 8 \end{matrix} \\ \begin{pmatrix} 0.4 & 0.1 \\ 0.9 & 0.7 \end{pmatrix} & \begin{matrix} 2 \\ 12 \end{matrix} \end{matrix}$$

Composição de Relações Nebulosas

- similar a uma multiplicação de matrizes
 - Porém tratar multiplicação como mínimo e adição como máximo
- Exemplo:

$$\mu_{p \circ m m}(1, 1) = \max(\min(0.9, 0), \min(0.4, 0.6), \min(0.1, 1)) = 0.4$$

Composição de Relações Nebulosas

- Composição Max-Produto

$$P \circ M(u, w) = \vee [\mu_P(u, v) \mu_M(v, w)]$$

- Composição Max-Estrela (★=t-norma)

$$P \circ M(u, w) = \vee [\mu_P(u, v) \star \mu_M(v, w)]$$

Propriedades de Relações Nebulosas

$$R \circ (S \circ T) = (R \circ S) \circ T$$

$$R \circ (S \cup T) = (R \circ S) \cup (R \circ T)$$

$$R \circ (S \cap T) \subseteq (R \circ S) \cap (R \circ T)$$

$$S \subseteq T \implies R \circ S \subseteq R \circ T$$

Leitura Recomendada

- Capítulo 3 do Livro - Seção 3.2.2.
 - Jyh-Shing Roger Jang and Chuen-Tsai Sun. 1996. *Neuro-Fuzzy and Soft Computing: A Computational Approach to Learning and Machine Intelligence*. Prentice-Hall, Inc., Upper Saddle River, NJ, USA.

