

Sistemas Nebulosos

Adaptive Neuro-Fuzzy Inference System (ANFIS)

Cristiano Leite de Castro

Adaptação de material didático do Prof. André Paim Lemos (DELT)

Modelagem utilizando Sistemas Nebulosos

- Sistemas nebulosos podem ser utilizados em tarefas de
 - Aproximação funcional
 - Controle de processos
 - Identificação de sistemas
 - Previsão de séries temporais
 - Classificação de padrões
 - Entre outros.

Sistemas Nebulosos Adaptativos

- Evolução das Técnicas de Modelagem
 - Primórdios:
 - definição do modelo a partir de conhecimento extraído de especialistas;
 - A partir da década de 90:
 - regras iniciais são geradas a partir do conhecimento de especialistas e/ou a partir de dados;
 - os parâmetros do modelo são ajustados a partir de dados;
 - Tendência atual
 - Modelos evolutivos;

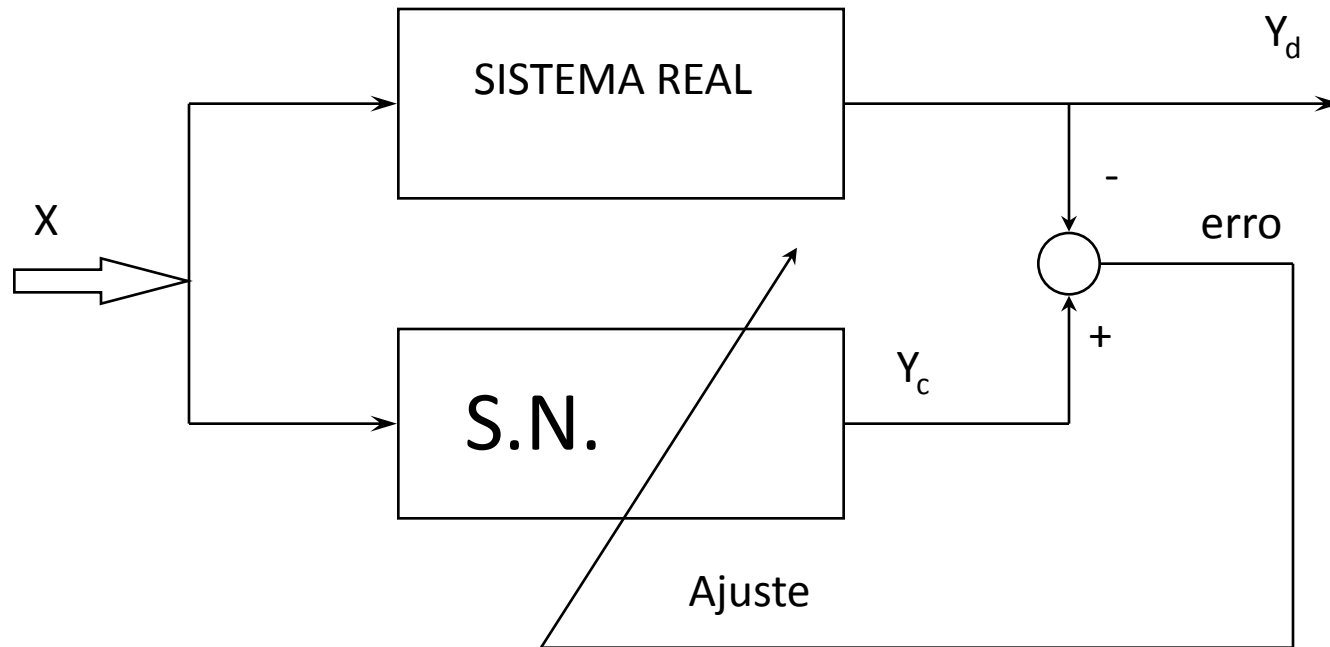
Sistemas Nebulosos Adaptativos

- Modelagem Atual:
 - pode-se ou não utilizar conhecimento de especialistas para definição da topologia inicial do modelo;
 - Caso não utilize:
 - topologia é definida a partir de dados de treinamento, utilizando, por exemplo, algoritmos de agrupamento;
 - parâmetros são ajustados utilizando algoritmos de otimização;
 - Exemplo: **Algoritmo do Gradiente Descendente**

Modelagem utilizando Sistemas Nebulosos

- Etapas do processo de modelagem:
 1. Definição das regras
 2. Escolha dos operadores
 3. Ajuste dos parâmetros
- Solução:
 - *Sistemas Nebulosos Adaptativos com parâmetros ajustados via gradiente descendente;*


SISTEMAS NEBULOSOS ADAPTATIVOS



PARÂMETROS DE AJUSTE

- funções de pertinência
- parâmetros dos modelos de saída
- base de regras

Estrutura da rede Neurofuzzy vista em sala de aula



Regras implementadas

Se $(x_1 \text{ é } A_{1j}) \text{ e } (x_2 \text{ é } A_{2j}) \dots (x_i \text{ é } A_{ij}) \dots (x_n \text{ é } A_{nj})$

Então $y_j = P_{1j}x_1 + P_{2j}x_2 + \dots + P_{ij}x_i + P_{nj}x_n + q_j$

$$y_j = \sum_{i=1}^n P_{ij} x_i + q_j$$

$$w_j = \prod_{i=1}^n \mu_{A_{ij}}(x_i)$$

$$w_j = \mu_{A_{1j}}(x_1) \cdot \mu_{A_{2j}}(x_2) \cdot \dots \cdot \mu_{A_{ij}}(x_i) \cdot \mu_{A_{nj}}(x_n)$$

$$\mu_{A_{ij}}(x_i) = \exp \left[\frac{-1}{2} \left(\frac{x_i - c_{ij}}{\sigma_{ij}} \right)^2 \right]$$

$$y_s = \frac{\sum_{j=1}^m w_j \cdot y_j}{\sum_{j=1}^m w_j} = \frac{a}{b}$$

$$\min e = \frac{1}{2} (y_s - y_d)^2$$

$$e = f(x, c_{ij}, \sigma_{ij}, p_{ij}, q_j)$$

Gradiente Descendente

- Regra de aprendizagem *Widrow-Hoff*:

$$w_j = w_j - \alpha(h_w(x^{(i)}) - y^{(i)})x_j^{(i)}$$

- também conhecida como método dos mínimos quadrados (*Least Mean Squares – LMS*)

Algoritmo Incremental (ou Estocástico)

Repita até convergir

{

Para $l = 1 \dots m$ // para todos os padrões de treinamento

{

Para $j = 1 \dots n$ // para todos os pesos

{

$$w_j = w_j - \alpha(h_w(x^{(i)}) - y^{(i)})x_j^{(i)}$$

}

}

}

Algoritmo

- Exemplo – MatLab.

Leitura Recomendada

- Capítulo 12 do Livro:
 - Jyh-Shing Roger Jang and Chuen-Tsai Sun. 1996. *Neuro-Fuzzy and Soft Computing: A Computational Approach to Learning and Machine Intelligence*. Prentice-Hall, Inc., Upper Saddle River, NJ, USA.

