

# Sistemas Nebulosos

## Introdução e Conjuntos Nebulosos

Cristiano Leite de Castro

Adaptação de material didático do Prof. André Paim Lemos (DELT)

# Cronograma


- Ver Cronograma Atualizado no Moodle.

# Avaliações

- Prova = 30
  - Lista de Exercícios = 5
  - Trabalho Prático 1 = 15
  - Trabalho Prático 2 = 20
  - Trabalho Prático 3 = 30
- Total = 100

# Como Estudar?

- Jyh-Shing Roger Jang and Chuen-Tsai Sun. 1996. *Neuro-Fuzzy and Soft Computing: A Computational Approach to Learning and Machine Intelligence*. Prentice-Hall, Inc., Upper Saddle River, NJ, USA.




- Notas de Aula (Slides) disponíveis no Moodle.
- Notas de Aula Prof. Von Zuben – FEEC – Unicamp (Moodle).
- Outras referências (complementares):
  - Witold Pedrycz and Fernando Gomide. 2007. *Fuzzy Systems Engineering: Toward Human-Centric Computing*. Wiley-IEEE Press.
  - George J. Klir and Bo Yuan. 1994. *Fuzzy Sets and Fuzzy Logic: Theory and Applications*. Prentice-Hall, Inc., Upper Saddle River, NJ, USA.

# Sistema Nebuloso

- Mapeamento não-linear de um vetor de entrada em uma saída escalar capaz de incorporar tanto conhecimento objetivo quanto conhecimento subjetivo.
  - conhecimento objetivo = modelo matemático (leis físicas que regem o sistema a ser modelado).
  - conhecimento subjetivo = especialista, regras linguísticas.
- Permite capturar **informações imprecisas** em linguagem natural e convertê-las para formato numérico.

# Sistema Nebuloso Adaptativo



- **Base de Regras:**
  - Se  $x_1$  é  $A_1$  e  $x_2$  é  $B_1$  então  $y$  é  $C_1$
  - Se  $x_1$  é  $A_2$  e  $x_2$  é  $B_2$  então  $y$  é  $C_2$
  - ...
  - Se  $x_1$  é  $A_m$  e  $x_2$  é  $B_m$  então  $y$  é  $C_m$

- **Conjunto de Dados:** $\{\vec{x}^k, y_d^k\}$  para  $k = 1 \dots N$

# Regras Nebulosas


- se temperatura é **muito quente** e pressão é **baixa** então gire v **um pouco para direita**.
- Conceitos importantes:
  - variáveis linguísticas (temperatura, pressão, v, etc.)
  - quantificadores (muito, um pouco, etc.)
  - conexões lógicas (e, ou, etc.)
  - rótulos línguisticos = conjuntos nebulosos (quente, baixa, direita, etc.)

# Exemplo

- *Tipping Problem:*
  - Given a number between 0 and 10 that represents the quality of service at a restaurant (where 10 is excellent), and another number between 0 and 10 that represents the quality of the food at that restaurant (again, 10 is excellent), what should the tip be?

# Exemplo

- *Tipping Problem:* (true system)



# Modelagem Nebulosa

- *Golden Rules of Tipping:* (**Especialista**)
  1. If the service is poor **or** the food is rancid, then tip is cheap.
  2. If the service is good, then tip is average.
  3. If the service is excellent **or** the food is delicious, then tip is generous.  
  - Assume that an average tip is 15%, a generous tip is 25%, and a cheap tip is 5%.

# Mapeamento Entrada-Saida

- Para o problema da gorjeta:

**INPUT:** service is 5.09 and food is 5.05

If the service is poor **or** the food is rancid, then tip is cheap.

If the service is good, then tip is average.

If the service is excellent **or** the food is delicious, then tip is generous.

---

**OUTPUT:** tip value?

# Mapeamento Entrada-Saida

- Para o problema da gorjeta:

**INPUT:** service is 5.09 and food is 5.05

If the service is poor **or** the food is rancid, then tip is cheap.

If the service is good, then tip is average.


If the service is excellent **or** the food is delicious, then tip is generous.

---

**OUTPUT:** tip value?

COMO É  
CALCULADO?


# Variáveis Linguísticas



# Variáveis Linguísticas

- Para o problema da Gorjeta:

1. If the service is poor **or** the food is rancid, then tip is cheap.
2. If the service is good, then tip is average.
3. If the service is excellent **or** the food is delicious, then tip is generous.



# Problema com Dicotomia

- Conjuntos Ordinários
  - Elementos são divididos em dois grupos distintos
    - MEMBROS = pertencem ao conjunto
    - NÃO-MEMBROS = não pertencem ao conjunto
  - Exemplos:
    - Números primos
    - Capitais do Brasil

# Problema com Dicotomia

- Realidade existem situações como:

*Grandes cidades do Brasil*

*Números próximos de 10*

*Pessoas Altas*

- Dificuldade em definir esses conjuntos utilizando conjuntos ordinários

# Problema com Dicotomia

*One seed does not constitute a pile nor two nor three... from the other side everybody will agree that 100 million seeds constitute a pile. What therefore is the appropriate limit? Can we say that 325 647 seeds don't constitute a pile but 325 648 do?*

Borel, 1950


# Conjuntos Nebulosos

- Conjuntos Nebulosos
  - Cada elemento possui um grau de pertinência ao conjunto entre [0,1]
  - Estende os conjuntos ordinários
    - Grau pertinência é 0 ou 1
  - Grau de pertinência = medida de similaridade entre o elemento e o conjunto


# Conjuntos Ordinários x Nebulosos

- *Pessoas Altas*

Conjunto Ordinário



Conjunto Nebuloso



# Logica Nebulosa

- Lógica
    - Ciência que tem por objetivo o estudo das leis do raciocínio
- 
1. Todos homens são mortais
  2. Sócrates é um homem
  3. Sócrates é mortal

# Logica Nebulosa

- Lógica Nebulosa
  - Ciência que se preocupa com os princípios formais do **raciocínio aproximado**
  - Procura modelar os modos imprecisos do raciocínio que tem um papel fundamental na habilidade humana de tomar decisões

# Inferencia Nebulosa

- Processo que produz conclusões a partir de um conjunto de regras **SE-ENTÃO** e **FATOS**.
  - Temperatura = 75°C – Pressão: 2 Psi

SE Temperatura é BAIXA E Pressão é ALTA ENTÃO Vazão é ALTA

SE Temperatura é MEDIA E Pressão é MEDIA ENTÃO Vazão é BAIXA

SE Temperatura é ALTA E Pressão é BAIXA ENTÃO Vazão é BAIXA

---

Vazão = ?

# Inferencia Nebulosa

- Inferência Nebulosa:
  - Para o problema da gorjeta:

INPUT: service is 5.09 and food is 5.05

If the service is poor **or** the food is rancid, then tip is cheap.


If the service is good, then tip is average.

If the service is excellent **or** the food is delicious, then tip is generous.

---

OUTPUT: tip?

# Inferência p/ o *Tipping Problem*




1. If the service is poor **or** the food is rancid, then tip is cheap.
2. If the service is good, then tip is average.
3. If the service is excellent **or** the food is delicious, then tip is generous.

# Inferência p/ o *Tipping Problem*

- Ativação das Regras:


	rancid	N/A	delicious
poor	cheap	cheap	cheap/generous
good	cheap/average	average	average/generous
excelent	cheap/generous	generous	generous

1. If the service is poor **or** the food is rancid, then tip is cheap.
2. If the service is good, then tip is average.
3. If the service is excellent **or** the food is delicious, then tip is generous.



# Inferência Nebulosa

Fornecidas por especialistas ou extraídas de dados numéricos



# Histórico

- Primeiro artigo
  - L. A. Zadeh, “Fuzzy Sets”, *Information and Control*, vol. 8, pp. 338-353, 1965

*“. . . the fact remains that . . . imprecisely defined ‘classes’ play an important role in human thinking, particularly in the domains of pattern recognition, communication of information and abstraction.”*



# Aplicações

- Controle
  - Controle de aeronave (Rockwell Corp)
  - Operação de metrô de Sendai (Hitachi)
  - Transmissão automática (Nissan, Subaru)
  - Self-Parking car (Tokyo Tech. Univ)
  - Space Shuttle docking (NASA)
- Otimização e Planejamento
  - Operação de elevadores (Hitachi, Fujitech, Mitsubishi)
  - Análise do mercado de ações (Yamaichi Securities)
- Análise de Sinais
  - Ajuste de imagem de TV (Sony)
  - Reconhecimento de escrita (Sony Palm Top)
  - Foco de câmera de vídeo (Sanyo/Fisher, Cannon)

# **Revisão de Conjuntos Ordinários**

# Definição e Representação

- Seja  $X$  o espaço de todos os elementos (Universo do discurso) e  $x$  um elemento arbitrário de  $X$ .
- Um conjunto ordinário  $A \subseteq X$ , é definido como uma coleção de elementos  $x \in X$ , tal que cada  $x$  pertence ou não pertence a  $A$ .
- Exemplo:  $A = \{1,2,5\}$  (Listagem dos membros)
- Função característica:  $\mu_A(x) = \begin{cases} 1 & \text{se } x \in A \\ 0 & \text{se } x \notin A \end{cases}$

# Função Característica

- Propriedades:

$$\mu_A(x) : X \rightarrow \{0, 1\}$$


$$\mu_X(x) = 1 \text{ e } \mu_\emptyset(x) = 0$$

X : Conjunto Universo ou Universo de Discurso

$\emptyset$  : Conjunto Vazio


# Função Característica

$$A = \{1, 2, 5\}$$



# Função Característica


$$A = \{x | 1 \leq x \leq 5\}$$



# Complemento

$$\bar{A} = \{x | x \notin A\}$$

$$A = \{x | 0 < x < 4\}$$



# União


$$A \cup B = \{x | x \in A \text{ ou } x \in B\}$$

- Pode ser generalizado para  $n$  conjuntos

$$\bigcup_{i \in I} A_i = \{x | x \in A_i \text{ para algum } i \in I\}$$

# União

$$A = \{x | 0 \leq x \leq 4\} \quad B = \{x | 3 \leq x \leq 5\}$$



# Intersecção



$$A \cap B = \{x | x \in A \text{ e } x \in B\}$$

- Também pode ser generalizado para  $n$  conjuntos

$$\bigcap_{i \in I} A_i = \{x | x \in A_i \text{ para todo } i \in I\}$$

# Intersecção

$$A = \{x | 0 \leq x \leq 4\} \quad B = \{x | 3 \leq x \leq 5\}$$



# Propriedades

$$A \cup B \implies \mu_{A \cup B}(x) = \max[\mu_A(x), \mu_B(x)]$$

$$A \cap B \implies \mu_{A \cap B}(x) = \min[\mu_A(x), \mu_B(x)]$$

$$\mu_{\bar{A}} = 1 - \mu_A x$$

# Exercício:

- Utilizando a função característica, prove a seguinte propriedade dos conjuntos clássicos:

$$A \cap \bar{A} = \emptyset$$

# Propriedades

Involution	$\overline{\overline{A}} = A$
Commutativity	$A \cup B = B \cup A$
)	$A \cap B = B \cap A$
Associativity	$(A \cup B) \cup C = A \cup (B \cup C)$ $(A \cap B) \cap C = A \cap (B \cap C)$
Distributivity	$A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$ $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$
Idempotence	$A \cup A = A$ $A \cap A = A$
Absorption	$A \cup (A \cap B) = A$ $A \cap (A \cup B) = A$
Absorption by $X$ and $\emptyset$	$A \cup X = X$ $A \cap \emptyset = \emptyset$
Identity	$A \cup \emptyset = A$ $A \cap X = A$
Law of contradiction	$A \cap \overline{A} = \emptyset$
Law of excluded middle	$A \cup \overline{A} = X$
De Morgan's laws	$\overline{A \cap B} = \overline{A} \cup \overline{B}$ $\overline{A \cup B} = \overline{A} \cap \overline{B}$

# Produto Cartesiano

$$A \times B = \{(a, b) | a \in A, b \in B\}$$

$$A = \{1, 2\}$$

$$B = \{a, e, i, o, u\}$$

$$\begin{aligned} A \times B = & \{(1, a), (1, e), (1, i), (1, o), (1, u), \\ & (2, a), (2, e), (2, i), (2, o), (2, u), \} \end{aligned}$$

# Partição

- Conjuntos A e B são disjuntos se

$$A \cap B = \emptyset$$

- Partição = família de subconjuntos de A

$$\pi(A) = \{A_i | i \in I, A_i \subseteq A\}$$



– Tal que

$$A_i \cap A_j = \emptyset; \forall i, j \in I, i \neq j \text{ e } \bigcup_{i \in I} A_i = A$$

# Partição

$U = \text{Conjunto dos Automóveis do Brasil}$

- Possíveis partições:



# **Conjuntos Nebulosos**

# Definição

- Seja  $X$  uma coleção de objetos denotados genericamente por  $x$ .
- Um conjunto *Fuzzy*  $A \subseteq X$ , é definido como uma coleção de pares ordenados:

$$A = \{(x, \mu_A(x)) | x \in X\}$$

onde  $\mu_A(x)$  é a **função de pertinência** para o conjunto A.

# Função de Pertinência

- pode assumir qualquer valor no intervalo entre 0 e 1;
- fornece o grau de similaridade entre o elemento e conceito (*rótulo linguístico*) expresso pelo conjunto;
- pode ser vista como uma generalização da **Função Característica** para conjuntos clássicos;
- permite modelar a imprecisão;
  - Notações:


$$\mu_A : X \rightarrow [0, 1]$$

(alternativa, encontrada em alguns livros)

# Exemplo: Conjunto Discreto

Seja  $X = \{1, 2, 3, 4, 5, 6\}$ , o número de filhos que uma família pode ter. O conjunto nebuloso discreto  $A$  = “número sensato de filhos” pode ser descrito como:

$$A = \{(0, 0.1), (1, 0.3), (2, 0.7), (3, 1), (4, 0.7), (5, 0.3), (6, 0.1)\}.$$



# Notação Alternativa

- Se  $X$  é discreto:

$$A = \sum_{x \in X} \mu_A(x_i) / x_i$$

- Exemplo:
  - Seja  $X = \{\text{Brasilia, Contagem, Fortaleza, Varginha, Vitoria}\}$ . O conjunto  $A = \text{"cidades próximas de Belo Horizonte"}$  pode ser descrito por:

$$A = 0.1/\text{Fortaleza} + 0.3/\text{Brasilia} + 0.6/\text{Vitoria} + 0.8/\text{Varginha} + 1/\text{Contagem}$$


# Exemplo: Conjunto Contínuo

Seja  $X = R^+$ , o conjunto de possíveis idades. Então, o conjunto nebuloso contínuo  $A$  = “ao redor de 50 anos” pode ser descrito como:

$$A = \{(x, \mu_A(x)) | x \in X\}$$

onde:

$$\mu_A(x) = \frac{1}{1 + \left(\frac{x - 50}{10}\right)^4}$$



# Notação Alternativa

- Se  $X$  (universo) é contínuo

$$A = \int_X \mu_A(x)/x$$

- Exemplo:
  - Seja  $X = R^+$ , o conjunto de possíveis idades.  
Então o conjunto  $A = \text{“ao redor de 50 anos”}$  pode ser expresso como :



$$A = \int_{R^+} \frac{1}{1 + \left(\frac{x - 50}{10}\right)^4} / x$$

# Observações:

- A definição de um conjunto *Fuzzy* depende da:
  1. identificação de  $X$  (universo do discurso) ;
  2. especificação de uma função de pertinência;
- Note que a especificação das funções de pertinência é **subjetiva**;
- Tal subjetividade advém das diferenças individuais em perceber ou expressar conceitos abstratos.


# Domínio

- universo total de valores possíveis para os elementos do conjunto ( $X$ )




# Supor te

- Subconjunto dos elementos que possuem valor de pertinência maior que 0, isto é



# Conjunto Nebuloso *Singleton*

- conjunto cujo suporte é um único ponto em  $X$ , com valor de pertinência igual a 1.





# **Funções de Pertinência mais utilizadas**

# Triangular

$$\mu(x; a, b, c) = \begin{cases} 0, & x \leq a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ \frac{c-x}{c-b}, & b \leq x \leq c \\ 0, & c \leq x \end{cases} \quad a < b < c$$


```
x = (0:0.2:10)';
y1 = trimf(x, [3 4 5]);
y2 = trimf(x, [2 4 7]);
y3 = trimf(x, [1 4 9]);
subplot(211), plot(x, [y1 y2 y3]);
y1 = trimf(x, [2 3 5]);
y2 = trimf(x, [3 4 7]);
y3 = trimf(x, [4 5 9]);
subplot(212), plot(x, [y1 y2 y3]);
set(gcf, 'name', 'trimf', 'numbertitle', 'off');
```



# Trapezoidal

$$\mu(x; a, b, c, d) = \begin{cases} 0, & x \leq a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & b \leq x \leq c \\ \frac{c-x}{c-b}, & c \leq x \leq d \\ 0, & c \leq x \end{cases} \quad a < b \leq c < d$$

```
x = (0:0.1:10)';
y1 = trapmf(x, [2 3 7 9]);
y2 = trapmf(x, [3 4 6 8]);
y3 = trapmf(x, [4 5 5 7]);
y4 = trapmf(x, [5 6 4 6]);
plot(x, [y1 y2 y3 y4]);
set(gcf, 'name', 'trapmf','numbertitle', 'off);
```





# Gaussiana

$$\mu(x; c, \sigma) = e^{-\frac{1}{2} \left( \frac{x-c}{\sigma} \right)^2}$$

$c$  representa o centro  
 $\sigma$  representa a largura

```
x = (0:0.1:10)';
y1 = gaussmf(x, [0.5 5]);
y2 = gaussmf(x, [1 5]);
y3 = gaussmf(x, [2 5]);
y4 = gaussmf(x, [3 5]);
subplot(211); plot(x, [y1 y2 y3 y4]);
y1 = gaussmf(x, [1 2]);
y2 = gaussmf(x, [1 4]);
y3 = gaussmf(x, [1 6]);
y4 = gaussmf(x, [1 8]);
subplot(212); plot(x, [y1 y2 y3 y4]);
set(gcf, 'name', 'gaussmf', 'numbertitle','off');
```




# Sino Generalizada

$$\mu(x; a, b, c) = \frac{1}{1 + \left| \frac{x-c}{a} \right|^{2b}}$$

$c$  representa o centro


$a$  representa a largura

$b$  representa a inclinação dos *crossover points*




# Sino Generalizada

$$\mu(x; a, b, c) = \frac{1}{1 + \left| \frac{x-c}{a} \right|^{2b}}$$



```
x = (0:0.1:10)';
y1 = gbellmf(x, [1 2 5]);
y2 = gbellmf(x, [2 4 5]);
y3 = gbellmf(x, [3 6 5]);
y4 = gbellmf(x, [4 8 5]);
subplot(211); plot(x, [y1 y2 y3 y4]);
y1 = gbellmf(x, [2 1 5]);
y2 = gbellmf(x, [2 2 5]);
y3 = gbellmf(x, [2 4 5]);
y4 = gbellmf(x, [2 8 5]);
subplot(212); plot(x, [y1 y2 y3 y4]);
set(gcf, 'name', 'gbellmf', 'numbertitle', 'off')
```





# Sigmoidal

$$\mu(x; a, c) = \frac{1}{1 + e^{-a(x-c)}}$$

$a$  controla a inclinação no crossover point  $x = c$   
 $a > 0$  então ela é aberta para direita  
 $a < 0$  então ela é aberta para esquerda

```
x = (0:0.2:10)';
y1 = sigmf(x, [-1 5]);
y2 = sigmf(x, [-3 5]);
y3 = sigmf(x, [4 5]);
y4 = sigmf(x, [8 5]);
subplot(211); plot(x, [y1 y2 y3 y4]);
y1 = sigmf(x, [5 2]);
y2 = sigmf(x, [5 4]);
y3 = sigmf(x, [5 6]);
y4 = sigmf(x, [5 8]);
subplot(212); plot(x, [y1 y2 y3 y4]);
set(gcf, 'name', 'sigmf', 'numbertitle', 'off');
```



# **Operadores Fuzzy**

# Operadores de Zadeh

- Complemento:

$$\bar{A} = X - A \iff \mu_{\bar{A}}(x) = 1 - \mu_A(x)$$


- União

$$A \cup B \iff \mu_{A \cup B}(x) = \max(\mu_A(x), \mu_B(x))$$

- Intersecção

$$A \cap B \iff \mu_{A \cap B}(x) = \min(\mu_A(x), \mu_B(x))$$

# Operadores de Zadeh



# Operadores Fuzzy

- Os operadores clássicos de **união**, **intersecção** e **complemento** foram propostos por *Zadeh* em seu artigo original;
- No entanto, ao longo dos anos, outros tipos de operadores de **complemento**, **união** e **intersecção** com propriedades específicas têm sido propostas na literatura;
- Tais operadores devem seguir um conjunto de requisitos básicos (axiomas) para que sua correspondência aos operadores de conjuntos ordinários seja válida.

# Complemento Nebuloso

- Função  $N : [0, 1] \rightarrow [0, 1]$  que calcula o complemento de uma função de pertinência:

$$\mu_{\bar{A}}(x) = N(\mu_A(x))$$

- Exemplo:

$$\mu_{\bar{A}}(x) = 1 - \mu_A(x)$$

# Complemento Nebuloso

- O Operador Complemento segue os seguintes axiomas:

Axioma n1:  $N(0) = 1$  e  $N(1) = 0$  (limite)

Axioma n2:  $N(a) \geq N(b)$  se  $a \leq b$  (monotonicidade)

Axioma n3:  $N(a)$  é contínua (opcional)

Axioma n4:  $N(N(a)) = a$  (opcional)


# Exemplos de Operadores de Complemento

Zadeh:  $N(a) = 1 - a$

Sugeno:  $N(a) = \frac{1 - a}{1 + sa} \quad s \in (-1, \infty)$

Yager:  $N(a) = (1 - a^w)^{1/w} \quad w \in (0, \infty)$

# Exemplos de Operadores de Complemento



# Exercício

- Prove que o complemento de Sugeno atende aos axiomas n1, n2 e n4:

$$N(a) = \frac{1-a}{1+sa} \quad s \in (-1, \infty)$$

$$N(0) = 1 \text{ e } N(1) = 0 \quad (\text{N1})$$

$$N(a) \geq N(b) \text{ se } a \leq b \quad (\text{N2})$$

$$N(N(a)) = a \quad (\text{N4})$$

# União Nebulosa

- Função  $S : [0, 1] \times [0, 1] \rightarrow [0, 1]$  que agrupa duas funções de pertinência:

$$\begin{aligned}\mu_{A \cup B}(x) &= S(\mu_A(x), \mu_B(x)) \\ &= \mu_A(x) \tilde{+} \mu_B(x)\end{aligned}$$

- Geralmente denominada **s-norma** (ou t-conorma)

# União Nebulosa

**Axioma s1:**  $S(0, 0) = 0$   $S(a, 0) = S(0, a) = a$  (limite)

**Axioma s2:**  $S(a, b) \leq S(c, d)$  se  $a \leq c$  e  $b \leq d$  (monotonicidade)

**Axioma s3:**  $S(a, b) = S(b, a)$  (comutatividade)

**Axioma s4:**  $S(a, S(b, c)) = S(S(a, b), c)$  (associatividade)

# União Nebulosa

Axioma s5:  $S(a)$  é contínua (opcional)

Axioma s6:  $S(a, a) = a$  (opcional)

*Um operador s-norma deve atender os axiomas s1 a s4.*

# Exemplos de s-normas

Máximo (s1-s6):


$$S(a, b) = \max(a, b)$$

Soma Probabilística (s1-s5):




$$S(a, b) = a + b - ab$$

# Exemplos de s-normas

Máximo



Soma Probabilística



# Intersecção Nebulosa

- Função  $T : [0, 1] \times [0, 1] \rightarrow [0, 1]$  que agrupa duas funções de pertinência:

$$\begin{aligned}\mu_{A \cap B}(x) &= T(\mu_A(x), \mu_B(x)) \\ &= \mu_A(x) \circledast \mu_B(x)\end{aligned}$$

- Geralmente denominada **t-norma** (norma triangular)

# Intersecção Nebulosa

**Axioma t1:**  $T(0, 0) = 0, \quad T(a, 1) = T(1, a) = a$  (limite)

**Axioma t2:**  $T(a, b) \leq T(c, d)$  se  $a \leq c$  e  $b \leq d$  (monotonicidade)

**Axioma t3:**  $T(a, b) = T(b, a)$  (comutatividade)

**Axioma t4:**  $T(a, T(b, c)) = T(T(a, b), c)$  (associatividade)

# Intersecção Nebulosa

Axioma t5:  $T(a)$  é contínua (opcional)

Axioma t6:  $T(a, a) = a$  (opcional)

*Um operador **t-norma** deve atender os axiomas t1-t4.*

# Exemplos de t-normas

Mínimo (t1-t6):


$$T(a, b) = \min(a, b)$$

Produto (t1-t5):




$$T(a, b) = ab$$

# Exemplos de t-normas

Mínimo



Produto



# Leitura Recomendada

- Capítulos 1 e 2
  - Jyh-Shing Roger Jang and Chuen-Tsai Sun. 1996. *Neuro-Fuzzy and Soft Computing: A Computational Approach to Learning and Machine Intelligence*. Prentice-Hall, Inc., Upper Saddle River, NJ, USA.

