

Universidade Federal de Minas Gerais
Engenharia Elétrica
Sistemas Nebulosos

Trabalho Prático 3

ANFIS

Aluno: Thiago Lages Rocha | 2015.123.320

Professor: Cristiano Leite de Castro

Belo Horizonte 2019.2

Sumário

1	Exercício 1 - Previsão de Série Temporal	2
2	Exercício 2 - Classificação de Padrões	5

List of Figures

1	Funções de pertencimento antes e depois do treinamento.	3
2	Série temporal explicitada, acima, e dados de treino (vermelho) e teste(verde), abaixo.	4
3	Previsões feitas pela ANFIS antes (acima) e depois (abaixo) do treinamento. A função real está em verde e a previsão em vermelho.	5
4	Evolução do erro para cada número de funções de pertencimento escolhida, para o dataset BreastCancer.	6
5	Evolução do erro para cada número de funções de pertencimento escolhida, para o dataset Iris.	7
6	Quatro funções de pertencimento para duas entradas, antes do treinamento.	8
7	Quatro funções de pertencimento para duas entradas, depois do treinamento.	8

1 Exercício 1 - Previsão de Série Temporal

Nesta primeira parte do trabalho é necessário usar uma ANFIS do tipo Takagi-Sugeno de ordem 1 para prever valores de uma série temporal, baseado em entradas passadas. No caso, foi escolhido lidar com valores 18, 12 e 6 instantes de tempo anteriores, bem como o instante atual, para prever um valor 6 instantes de tempo após o instante atual. Desta forma, a entrada é do tipo $[x(t-18), x(t-12), x(t-6), x(t)]$, e a saída é do tipo $x(t+6)$.

Optou-se por utilizar duas funções de pertencimento inicialmente, ilustradas na parte superior da figura 1, de modo a verificar se os resultados seriam suficientes. Utilizando a função *genfis1*, que cria um sistema de inferência Fuzzy a partir de dados usando partição em grid, temos que as funções de pertencimento são igualmente espaçadas dentro o intervalo definido pelos dados.

No caso desta questão, os valores $\min(Y) = 0.4256$ e $\max(Y) = 1.3137$, o que justifica a colocação destas funções de pertencimento como mostra a figura 1. Apesar disso, após o treinamento proposto, observa-se que as funções de pertencimento foram alteradas, de maneira que ambas diminuíram sua variância, e a curva laranja teve sua média aumentada.

Na figura 2 é possível observar a série temporal completa na parte de cima, e os dados de treino e teste na parte de baixo, nas cores vermelha e verde, respectivamente. A partição dos dados foi feita de maneira que os primeiros 80% compusessem a parte de treino, e os 20% restantes fossem usados para teste. Escolheu-se separar os dados dessa maneira pois é uma série periódica, ou seja, se repete a cada intervalo T . Desta forma, temos que não importa qual intervalo os dados de teste fossem pegos; se estes fossem contíguos, pelo fato de ser uma série periódica, teríamos os mesmos pontos no fim das contas, apenas deslocados espacialmente.

Apenas criando-se um sistema de inferência a partir das funções de pertencimento iniciais, e sem fazer um treinamento adequado, obtém-se a curva em vermelho na parte de cima da figura 3. O sistema não é capaz de fazer qualquer inferência significativa antes do treinamento. Apesar disso, após o treinamento, utilizando-se a função *anfis* e passando os dados de treino bem como o sistema anteriormente criado, em um máximo de 100 iterações, obtém-se a saída na parte de baixo da figura 3. O sistema é capaz de prever muito bem a série temporal, dando um resultado de erro médio quadrático de $2.9625e-06$ no teste, e de $2.5849e-06$ no treino. É possível perceber que, tanto para dados de treino como para dados de teste, o resultado é muito bom, se aproximando muito de cada ponto no gráfico.

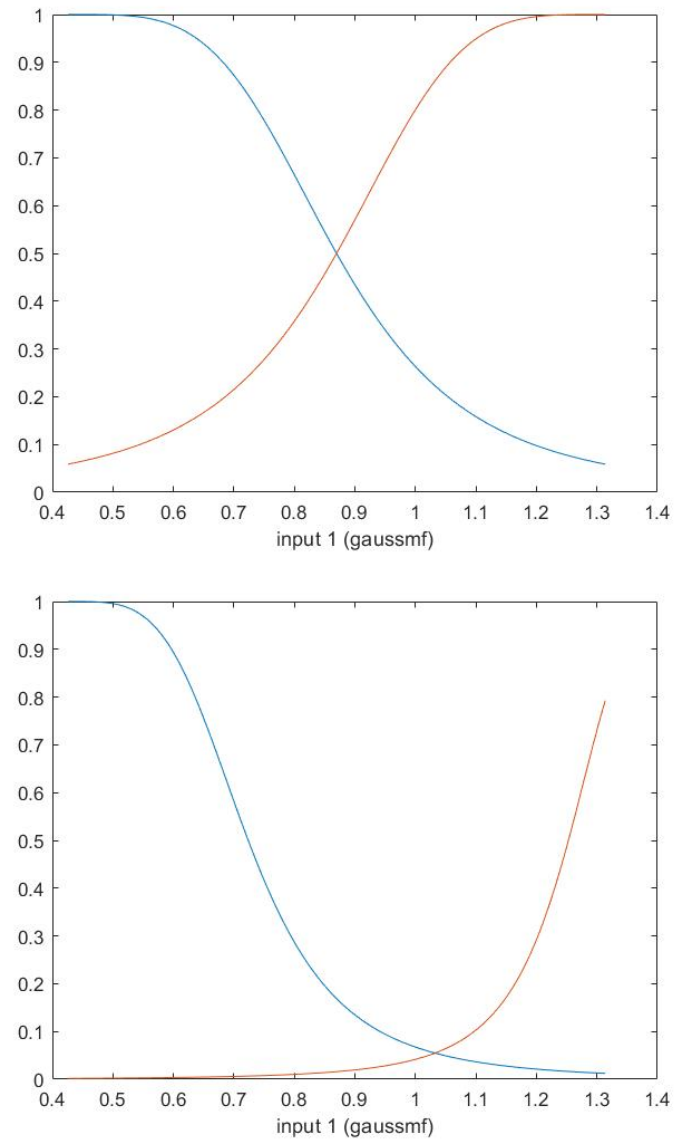


Figure 1: Funções de pertencimento antes e depois do treinamento.





Figure 2: Série temporal explicitada, acima, e dados de treino (vermelho) e teste(verde), abaixo.




Figure 3: Previsões feitas pela ANFIS antes (acima) e depois (abaixo) do treinamento. A função real está em verde e a previsão em vermelho.

2 Exercício 2 - Classificação de Padrões

A segunda parte do trabalho consiste em utilizar uma base de dados disponível na internet para fazer sua classificação. Foram utilizadas duas bases: a de câncer de mama, chamada de *BreastCancer* e a base *Iris*, muito conhecida no mundo de ciência dos dados e reconhecimento de padrões.

Era preciso subdividir os dados de treino e teste em proporção de 7:3, e fazer uma seleção de modelos baseado em hiperparâmetros. Como já sabemos, é necessário definir funções de pertencimento, bem como o número de regras a serem utilizadas (ou número de funções de pertencimento). Desta forma projetou-se um sistema do tipo Takagi-Sugeno de ordem 1 e testou-se inicialmente as funções e pertencimento do tipo Gaussiana, Sino, Triangular e Trapezoidal. Dentre essas, a Gaussiana apresentou melhor resultado e a partir daí, variou-se o número de funções de pertencimento entre 2 e 5 a fim de analisar os resultados.

Número de MFs	Erro Treino	Acurácia Treino	Acurácia Teste
2	0.153238	97.14%	95.714%
3	0.124460	98.28%	94.762%
4	0.090912	99.28%	96.19%
5	0.095362	99.00%	92.857%

Table 1: Erro e acurácia para treino e teste, para diferentes números de funções de pertencimento, no dataset BreastCancer.

Número de MFs	Erro Treino	Acurácia Treino	Acurácia Teste
2	3.19186e-05	100%	100%
3	5.01066e-07	100%	100%
4	3.52692e-07	100%	100%
5	6.70658e-06	100%	100%

Table 2: Erro e acurácia para treino e teste, para diferentes números de funções de pertencimento, no dataset Iris.




Figure 4: Evolução do erro para cada número de funções de pertencimento escolhida, para o dataset BreastCancer.

É notável a diminuição do erro quanto maior é o número de funções de pertencimento, tanto na questão de queda mais abrupta no início do treinamento, quanto ao atingir um menor valor assintótico de erro. Apenas no caso entre 4 e 5 funções de pertencimento, tivemos uma queda maior ao final com quatro MFs, ao invés de cinco.




Figure 5: Evolução do erro para cada número de funções de pertencimento escolhida, para o dataset Iris.

No caso do dataset Iris, a ANFIS foi capaz de acertar 100% dos dados de treino e teste, e a evolução do erro ao longo das iterações é mostrado na figura 5. Mais uma vez, quanto maior o número de funções de pertencimento, menor o erro, mesmo que neste caso os valores de erro já comecem bem baixos.

Na figura 4 percebe-se que o decrescimento do erro em todos os casos segue mais ou menos o mesmo perfil: decaimento rápido nos instantes de tempo iniciais, e depois a curva segue assintoticamente para algum valor. Para o caso de quatro funções de pertencimento, temos que o erro mínimo atingido foi de 0.090912, o menor entre todos. Desta forma, o número de MFs selecionado foi justamente de 4.




Figure 6: Quatro funções de pertencimento para duas entradas, antes do treinamento.

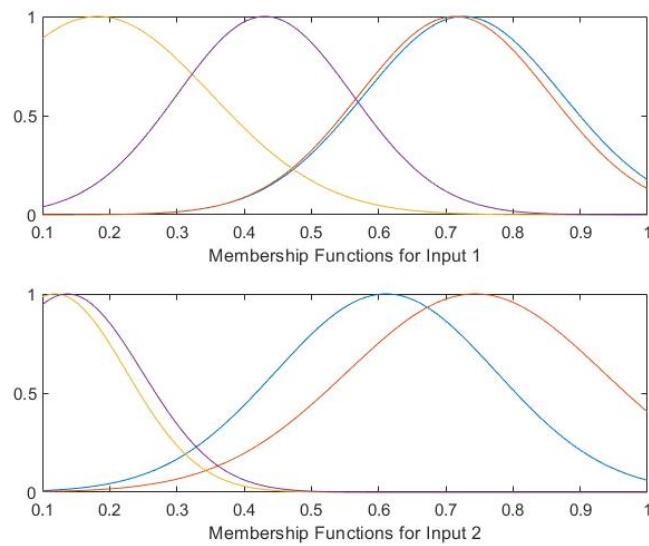


Figure 7: Quatro funções de pertencimento para duas entradas, depois do treinamento.